

Derin Öğrenme Tabanlı Otomatik Beyin Tümör Tespiti

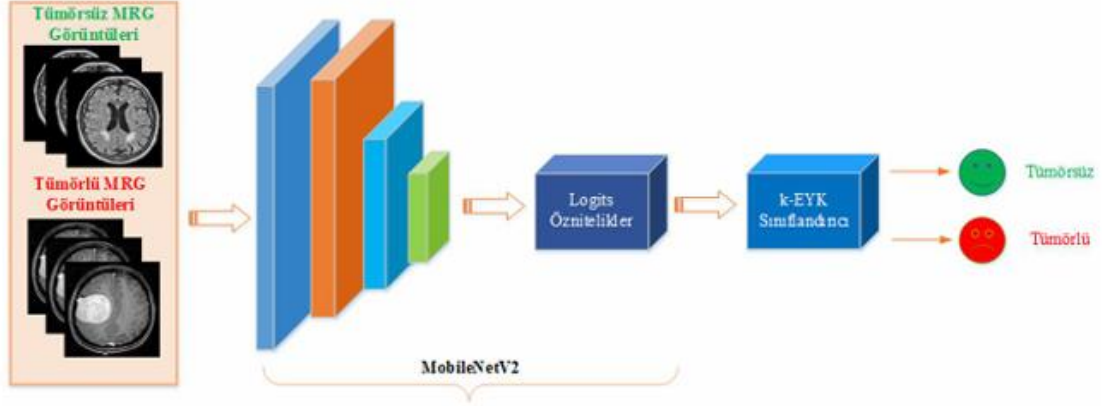
Giriş ve Amaç

Araştırmanın Konusu ve Önemi

- **Beyin Tümörleri:**
Beyin tümörleri, dünya genelinde önde gelen ölüm nedenlerinden biri olup erken teşhis hayat kurtarıcı rol oynamaktadır.
- **MRG Kullanımı:**
Manyetik rezonans görüntüleme (MRG), beynin yumuşak dokusuna dair yüksek çözünürlüklü ve şekilsel bilgiler sunarak tümör tespitinde tercih edilen bir yöntemdir.
- **Otomatik Tanı İhtiyacı:**
Geleneksel, manuel yöntemlerin zaman alıcı ve hata yapma olasılığının yüksek olması nedeniyle, yapay zekâ tabanlı otomatik tespit sistemleri uzmanlara destek sağlamakta ve teşhis sürecini hızlandırmaktadır.

Çalışmanın Amaçları ve Katkıları

- **Amaç:**
MRG görüntülerinden beyin tümörlerini otomatik olarak tespit edebilen etkili ve yüksek doğruluklu bir model geliştirmek.
- **Kullanılan Yöntem:**
Önerilen sistemde, önceden eğitilmiş MobileNetV2 ESA modeli kullanılarak derin öznetelik çıkarımı gerçekleştirilmiş; ardından bu öznetelikler k-en yakın komşu (k-EYK) sınıflandırıcısı ile sınıflandırılmıştır.
- **Katkılar:**
 - Düşük hesaplama gücüne sahip cihazlarda dahi çalışabilecek hafif model kullanımı.
 - Veri çoğaltma (augmentation) ile sınırlı veri setinin genişletilmesi.
 - K-EYK sınıflandırıcısı ile %96,44 doğruluk gibi yüksek başarımlar elde edilmesi.



Şekil 1: Önerilen modelin blok diyagramı

Materyal, Metodoloji ve Uygulama

Veri Seti ve Veri Çoğaltma

- **Veri Seti:**
Toplam 253 MRG görüntüsünden oluşan veri seti, 155 tümörlü ve 98 tümörsüz görüntüyü içermektedir.
- **Veri Çoğaltma:**
Görüntüler, yatay ve dikey çevirme, 90° ve 270° döndürme gibi yöntemlerle çoğaltılarak toplam 1265 görüntüye çıkarılmıştır.
- **Amaç:**
Veri setinin genişletilmesi, modelin genelleme performansını artırmak ve aşırı ezberleme (overfitting) riskini azaltmaktır.

Model ve Yaklaşımlar

- **Transfer Öğrenimi ve MobileNetV2:**
 - MobileNetV2, ImageNet üzerinde eğitilmiş bir ESA modeli olarak kullanılmış; bu sayede önceden öğrenilmiş derin öznitelikler çıkarılmıştır.
 - Modelin “Logits” tam bağlı katmanından alınan 1000 derin öznitelik, sonraki sınıflandırma için temel oluşturmuştur.
- **k-En Yakın Komşu (k-EYK) Sınıflandırıcı:**
 - Çıkarılan derin öznitelikler, k-EYK sınıflandırıcısına uygulanarak, komşuların çoğunluk oyu ile görüntüler sınıflandırılmıştır.

- k değeri 5 olarak belirlenmiş ve 5 kat çapraz doğrulama yöntemi kullanılmıştır.
- **Performans Ölçütleri:**
Doğruluk, duyarlılık, özgüllük, keskinlik, F1 skoru ve Matthews Korelasyon Katsayısı (MCC) gibi kriterlerle model performansı değerlendirilmektedir.

Deneysel Uygulama

- Deneyler, MATLAB derin öğrenme araç kutusu kullanılarak, GPU destekli bir sistemde gerçekleştirilmiştir.
- MobileNetV2'nin parametreleri SGDM optimizasyon algoritması, sabit öğrenme oranı (0.0001), düşük yığın boyutu ve 5 tekrar üzerinden optimize edilmiştir.

Sonuçlar, Karşılaştırmalar ve Gelecek Perspektifleri

Deneysel Sonuçlar

- **Orijinal Veri Üzerinde:**
MobileNetV2 ESA modeli ve k-EYK sınıflandırıcısı, orijinal veri setinde sırasıyla %86,56 ve %89,72 doğruluk oranlarına ulaşmıştır.
- **Veri Çoğaltma Sonrası:**
Veri çoğaltma uygulandıktan sonra, MobileNetV2 Logits katmanından çıkarılan özniteliklerle k-EYK kullanılarak yapılan sınıflandırmada;
 - Doğruluk: %96,44
 - Duyarlılık: %96,94
 - Özgüllük: %96,13
 - Keskinlik: %94,06
 - F1 Skoru: %95,48
 - MCC: 0,925
 gibi üstün performans değerleri elde edilmiştir.

| Veri Seti | Yöntem | Doğruluk | Duyarlılık | Özgüllük | Keskinlik | F1 Skor | MCC |
|-------------|-------------|----------|------------|----------|-----------|---------|-------|
| Orijinal | MobileNetV2 | 86,56 | 86,73 | 86,45 | 80,19 | 83,33 | 0,722 |
| | k-EYK | 89,72 | 88,78 | 90,32 | 85,29 | 87,00 | 0,785 |
| Çoğaltılmış | MobileNetV2 | 92,89 | 91,84 | 93,55 | 90,00 | 90,90 | 0,850 |
| | k-EYK | 96,44 | 96,94 | 96,13 | 94,06 | 95,48 | 0,925 |

Tablo 1: Orijinal ve çoğaltılmış veri setlerinde MobileNetV2 ve k-EYK performans karşılaştırma sonuçları

- **Karşılaştırma:**
Önerilen yöntem, aynı veri seti üzerinde çalışan diğer ESA tabanlı modellerle karşılaştırıldığında daha hafif yapı ve daha yüksek sınıflandırma doğruluğu sağlamıştır.

| Yöntem | Model | Doğruluk (%) |
|----------------------------|-------------------|--------------|
| Arı ve diğerleri [8] | Bölütleme+k-NN | 86,39 |
| Bulut ve diğerleri [9] | MRF | 87,00 |
| Mohsen ve diğerleri [10] | ADD+PCA | 93,94 |
| Afşar ve diğerleri [11] | CapsNet | 86,56 |
| Vani ve diğerleri [12] | DVM | 81,48 |
| Çıtak ve diğerleri [13] | DVM+ÇKA+LR | 93,00 |
| Shahzadi ve diğerleri [14] | VGG+UKSB | 84,00 |
| Swati ve diğerleri [15] | VGG19 | 94,82 |
| Saxena ve diğerleri [17] | ResNet50 | 95,00 |
| Önerilen Yöntem | MobileNetV2+k-EYK | 96,44 |

Tablo 2: Bazı yöntemlerin performans karşılaştırmaları

Değerlendirme ve Sonuçlar

- **Genel Başarım:**
Önerilen yöntem, derin öznitelik çıkarımı ve k-EYK sınıflandırması sayesinde beyin tümörü tespitinde yüksek performans göstermiştir.
- **Verimlilik:**
Transfer öğrenimi sayesinde eğitim süresi kısalmış, öznitelik çıkarım süreci yaklaşık 3 dakikada tamamlanmıştır.
- **Uygulama Kolaylığı:**
Model, düşük kapasiteli donanımlarda dahi çalışabilir ve otomatik teşhis sistemleri için uygulanabilirliği yüksektir.

Gelecek Çalışma Önerileri

- **Model Geliştirmeleri:**
Farklı beyin tümörü tiplerini ayırt edebilecek daha geniş veri setleri ve yeni model mimarileri üzerinde çalışmalar yapılması.
- **Performans İyileştirmeleri:**
Ek hiper parametre optimizasyonları ve farklı sınıflandırıcıların denenmesi.

- **Klinik Uygulama:**

Geliştirilen modelin, klinik ortamda radyologlara karar verme sürecinde destek olması hedeflenmektedir.